

Кафедра дискретной математики МФТИ

Курс математической статистики

Игашов Илья, 593 группа

## Задание №4

### №3

Рассмотрим  $X_1, \dots, X_n \sim \text{Bern}(\theta)$ . По сетке значений  $\theta \in [0, 1]$  с шагом 0,01 постройте график зависимости нижней оценки дисперсии произвольной несмещенной оценки из неравенства Рао-Крамера от  $\theta$ . Какой можно сделать вывод (напишите в комментариях)? Для каждого значения  $\theta$  (для той же сетки) сгенерируйте выборку размера  $n = 1000$  для параметра  $\theta$ , посчитайте эффективную оценку  $\hat{\theta}$  и бутстрепную оценку дисперсии (параметрический бутстреп, количество бутстрепных выборок равно 500) этой эффективной оценки  $\hat{\theta}$ . Нарисуйте график зависимости полученных бутстрепных оценок от  $\theta$ .

In [1]:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom

%matplotlib inline
```

In [2]:

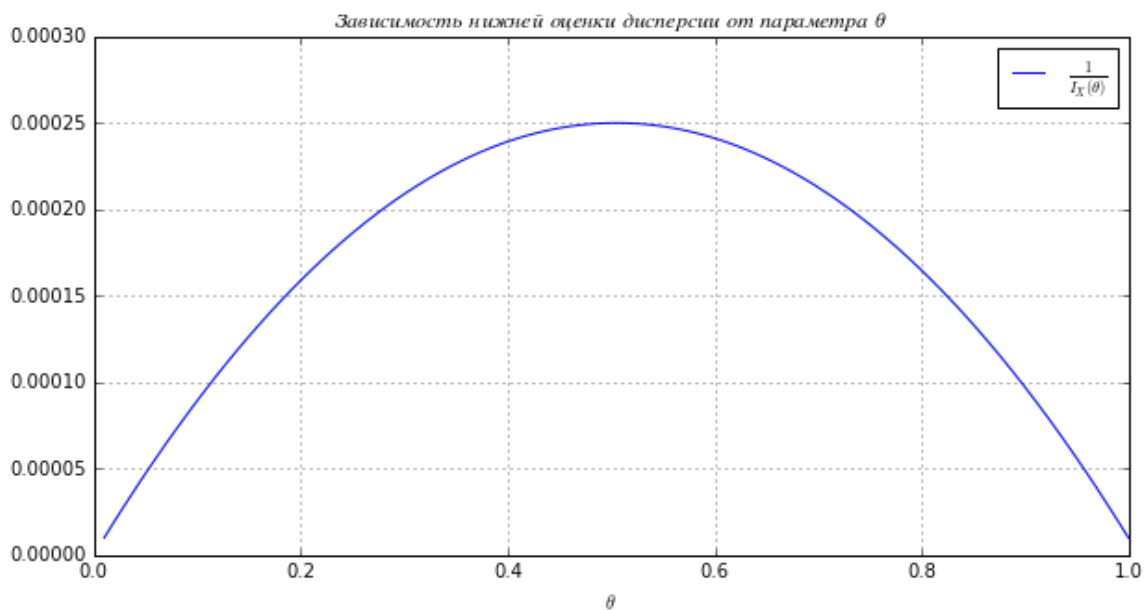
```
# Считаем информацию Фишера для разных значений параметра theta:
Fisher = np.array([1 / (theta * (1 - theta)) for theta in np.arange(0.01, 1, 0.01)])
```

In [3]:

```
# Строим график:
```

```
N = 1000
plt.figure(figsize=(10, 5))
plt.plot(np.linspace(0.01, 1, 99), 1 / (N * Fisher), label=r'$\frac{1}{I_X(\theta)}$')
plt.ylim(0, 0.0003)

plt.legend()
plt.title(r'$Зависимость \ нижней \ оценки \ дисперсии \ от \ параметра \ \theta$')
plt.xlabel(r'$\theta$', fontsize='10')
plt.grid()
plt.show()
```



Можно сделать вывод, что при  $\theta = 0,5$  функция нижней оценки дисперсии  $\frac{1}{I_X(\theta)} = \frac{1}{n \cdot i(\theta)}$  достигает максимума, что означает, что при данном значении параметра в одном наблюдении содержится минимальное количество информации Фишера.

In [4]:

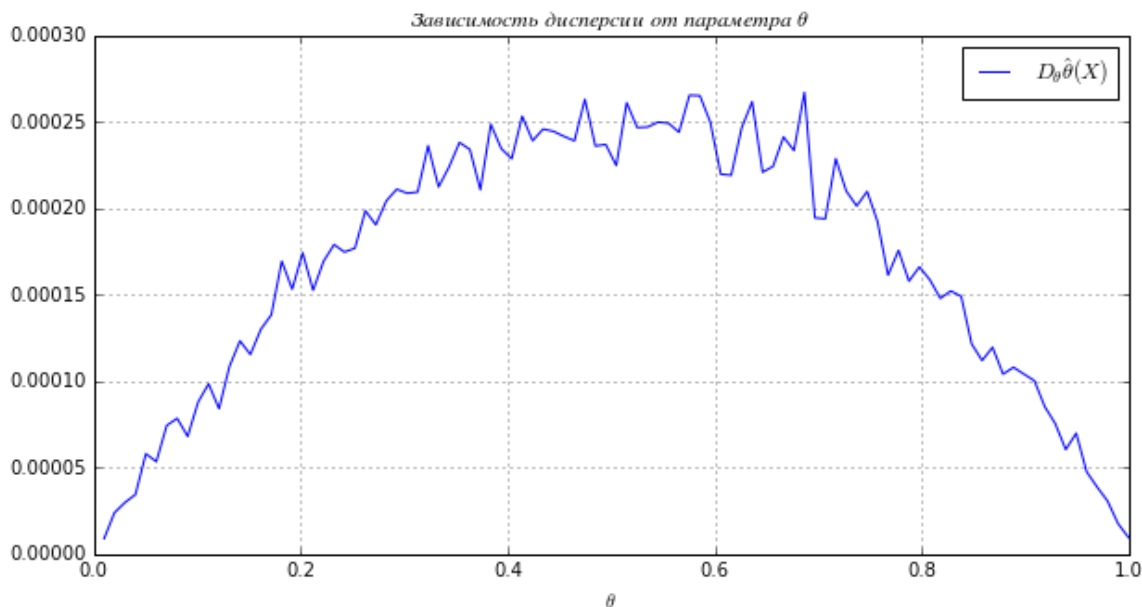
```
# Для каждого theta из сетки генерим выборку размера N, для нее считаем оценку,  
# По этой оценке генерим K бутстрепных выборок размера N,  
# Для каждой бутстрепной выборки считаем оценку по ней и считаем дисперсию полученных K оценок.
```

```
K = 500  
variance = []  
for theta in np.arange(0.01, 1, 0.01):  
    sample = binom.rvs(1, theta, size=N)  
    eff_estimate = np.cumsum(sample) / [1 + n for n in range(N)]  
    b_samples = np.array([binom.rvs(1, eff_estimate[N - 1], size=N) for k in range(K)])  
    b_effs = np.array([np.cumsum(b_samples[k]) / [1 + n for n in range(N)] for k in range(K)])  
    b_var = np.sum(np.array([b_effs[k][N - 1] for k in range(K)]) ** 2) / K - (np.sum([b_effs[k][N - 1] for k in range(K)]) / K) ** 2  
    variance.append(b_var)
```

In [5]:

```
# Строим график зависимости дисперсии от theta.
```

```
plt.figure(figsize=(10, 5))  
plt.plot(np.linspace(0.01, 1, 99), variance, label=r'$D_{\hat{\theta}}(\theta(X))$')  
  
plt.legend()  
plt.title(r'$Зависимость \ дисперсии \ от \ параметра \ \theta$')  
plt.xlabel(r'$\theta$', fontsize='10')  
plt.grid()  
plt.show()
```



## Вывод

$$D_{\theta}\hat{\theta}(X) = D_{\theta}(\bar{X}) = \dots = \frac{\theta(1-\theta)}{n}$$
$$I_X(\theta) = n * i(\theta) = \frac{n}{\theta(1-\theta)}$$

По определению эффективной оценки неравенство Крамера-Рао должно превращаться в равенство:

$$D_{\theta}\hat{\theta}(X) = \frac{1}{I_X(\theta)} = \frac{1}{n * i(\theta)}$$

Из графиков видно, что равенство в неравенстве Крамера-Рао выполняется, и оценка  $\bar{X}$  действительно является эффективной для распределения Бернулли.